碩士班課程 HW2 — 多元線性回歸專題研究報告

遵循 CRISP-DM 流程之特徵選擇、統計假設診斷與 95% 預測區間推論

> 課程層級：碩士班課程作業（Graduate-Level Course Project）
> 作業項目：HW2 — Multiple Linear Regression Research Report
> 研究代碼庫：https://github.com/sam052003/Multiple-Linear-regression
> 分支：migration/vercel
> 實驗環境：Python 3.14 / Scikit-learn 1.6 / Statsmodels 0.14 / ReportLab 5.1
> 分析日期：2026-10-28

摘要 (Abstract)

本研究以跨產業資料探勘標準流程 CRISP-DM (Cross-Industry Standard Process for Data Mining) 六大階段為方法論骨幹，系統性探討多元線性回歸 (Multiple Linear Regression, MLR) 在公開合成教育基準資料與環境物理合成競賽數據中的泛化預測行為、特徵篩選機制與計量統計推論界限。

主要研究對象為 Kaggle Student Performance Factors 公開模擬資料集（6,607 筆觀測值、19 個原始特徵，符合作業規定之 14～39 個原始特徵規格），並輔以 Kaggle Flood Probability Prediction 資料集（30,000 筆固定隨機抽樣）進行跨資料生成結構之對比研究。研究全程落實嚴格的防範資料洩漏 (Leakage-Free) 前處理管線，並在 80/20 訓練/測試切分與 5 折交叉驗證架構下，系統性比較 Baseline（全特徵基準）與 5 種主流特徵選擇方法：Filter (SelectKBest)、Wrapper (RFE)、Wrapper (Forward SFS)、Embedded (LassoCV) 與 Model-based (Permutation Importance)。

核心實證發現：

1. 基準模型可重現性：Student Performance Baseline 測試集決定係數實測重現為 $R^2 = 0.769650$（RMSE = 1.804445，MAE = 0.452392）；Flood Probability Baseline 測試集決定係數實測重現為 $R^2 = 0.844545$（RMSE = 0.019983，MAE = 0.015939）。

2. Lasso 保留全部特徵之統計本質：在 N = 5,285 的充沛訓練樣本下，5 折交叉驗證選定之最優懲罰參數極小（$\alpha = 0.002271$），所有 27 個編碼特徵之回歸係數絕對值均大於數值截斷閥值 10^(-5)。實證揭露：在大樣本下殘差平方和梯度主導了目標函數，即使微弱預測力之變數亦能使交叉驗證 MSE 微幅下降，故未被 L1 懲罰完全歸零。

3. 特徵排序與評估準則之分歧：實證推翻了「特定三項特徵在所有方法中均排名前三」的假設。研究顯示 Attendance（出席率）與 Hours_Studied（學習時數）在所有演算法中穩居前二名；但第三名特徵因演算法目標函數而顯著分歧：單變量 Filter 依據無條件相關性挑選 Previous_Scores，而多變量回歸 Wrapper (RFE) 與 Lasso 則因多變量條件回歸中，類別虛擬變數基準組位移幅度較大，優先保留了 Access_to_Resources_Low 與 Parental_Involvement_Low，完全剔除了 Previous_Scores。

4. 特徵縮減之訊號結構對比：在 Student 資料集中，將特徵由 27 個降至 5 個時，最佳子集（Permutation Importance）測試集 R^2 為 0.666460（解釋力保留率 86.6%），主因訊號高度集中於核心行為特徵；但在 Flood 資料集中，特徵由 20 個降至 5 個時，最佳子集（RFE (Wrapper)）測試集 R^2 跌至 0.180733（解釋力保留率僅 21.4%），實證確認了在廣泛分散型訊號架構下激進的特徵縮減將招致嚴重的遺漏變數偏差。

5. 95% 預測區間與統計診斷界限：實證解析母體均值信賴區間 (CI，平均寬度 0.5913) 與個別觀測值預測區間 (PI，平均寬度 8.2190) 之 13.9 倍本質差異。回歸五大假設診斷客觀揭露殘差常態性因成績界限截斷而遭拒絕，並指出大樣本中央極限定理 (CLT) 雖保障參數漸近常態，但不保證單一個體預測區間在厚尾下的絕對有效性。

---

1. 商業與研究問題理解 (Business Understanding)

1.1 研究動機與背景

在教育數據探勘 (Educational Data Mining, EDM) 與學習成效分析中，建立可解釋的統計模型以輔助學業表現預警，是教育決策支援系統的重要基石。多元線性回歸 (MLR) 具備最直觀的邊際權重解釋性與堅實的漸近統計性質，適合作為探索各項學習因素關聯度的基準模型。

1.2 研究問題定義 (Research Questions)

本研究具體聚焦於以下四項核心科學問題：

- RQ1（預測能力極限）：在結合學習習慣、過往成績、家庭資源與環境條件等 19 項原始輸入特徵下，多元線性模型對最終考試成績 (Exam_Score) 的線性解釋變異量極限為何？
- RQ2（維度縮減與效能權衡）：透過 Filter、Wrapper、Embedded 與 Model-based 等不同哲學之特徵篩選技術，能否在大幅精簡模型變數（縮減至 K = 5）的同時，維持統計泛化能力？何種情況會引發效能顯著衰退？
- RQ3（特徵重要性之一致性與分歧）：單變量顯著性（無條件相關係數與 F 檢定）與多變量條件權重（OLS 係數、L1 正則化、排列重要度）在評估特徵重要性時存在何種系統性分歧？
- RQ4（區間推論與決策可靠性）：點預測無法反映預測不確定性。如何透過嚴謹的 95% 預測區間 (Prediction Interval) 提供個別學生未來的成績區間估計？其與母體均值信賴區間 (Confidence Interval) 有何本質區別？

1.3 重要科學限制揭露：統計關聯性 vs. 因果推論 (Correlation is NOT Causation)

多元線性回歸模型所估計之係數 $\beta_j = dE[Y|X] / dX_j$，在計量統計上僅代表在控制模型內其他變數不變之條件下，該自變數與目標變數間的統計邊際關聯度 (Partial Statistical Association)。

本研究鄭重聲明：

> 「高度統計顯著性與較大回歸係數，絕不等同於因果關係 (Correlation does NOT imply Causation)。」

在缺乏自然實驗 (Natural Experiment)、工具變數 (Instrumental Variables) 或隨機對照試驗 (RCT) 的前提下，觀測資料中極可能存在未衡量的潛在混淆變數（如學生天賦能力、內在求知動機或家庭隱性社會資本）。因此，本研究之特徵重要性分析僅供預測建模與特徵篩選參考，決策者絕不可逕行將負向係數（如 Access_to_Resources_Low）解讀為單一因果政策介入之槓桿點。

---

2. 資料探索與理解 (Data Understanding)

2.1 主研究資料集：Student Performance Factors 之資料性質揭露

- 資料來源與性質：本資料集取自 Kaggle 公開機器學習教育資料庫（lainguyn123/student-performance-factors）。依據其資料庫說明，本資料集屬於依據學生學習習慣與學業表現特徵所構建之公開模擬 / 合成教育基準資料集 (Synthetic/Simulated Benchmark Dataset)，旨在提供回歸演算法公平測試與教育數據探勘評估基準，並非真實受訪學生之田野調查記錄。本研究採客觀資料科學視角探討其變數間之數值關聯。
- 資料規模：6,607 筆觀測記錄，共 20 個欄位（19 個輸入特徵 + 1 個連續目標變數 Exam_Score）。
- 特徵屬性與編碼結構：
- 數值連續特徵 (6 項)：Hours_Studied（學習時數，1～44）、Attendance（出席率，60～100%）、Sleep_Hours（睡眠時數，4～10）、Previous_Scores（過往成績，40～100）、Tutoring_Sessions（課外輔導次數，0～8）、Physical_Activity（每週運動時數，0～6）。
- 類別名義/順序特徵 (13 項)：Parental_Involvement（家長參與度）、Access_to_Resources（學習資源取得度）、Extracurricular_Activities（課外活動參與）、Motivation_Level（學習動機水準）、Internet_Access（網路連線）、Family_Income（家庭收入水準）、Teacher_Quality（教師教學品質）、School_Type（學校體制）、Peer_Influence（同儕影響力）、Learning_Disabilities（學習障礙）、Parental_Education_Level（父母最高學歷）、Distance_from_Home（住家與學校距離）、Gender（學生生理性別）。
- 未填記錄與缺失處置之客觀陳述：
- 檢視發現 Teacher_Quality（93 筆）、Parental_Education_Level（103 筆）與 Distance_from_Home（97 筆）欄位存在少量未填記錄。由於公開資料集未提供缺失機制之受訪背景或實驗日誌，本研究不逕行假設其符合統計上的隨機缺失 (MAR)。為維持後續多元回歸設計矩陣之完整性，本研究於訓練集採用眾數補值 (Most Frequent Imputation) 作為實務工程處置，並嚴格將補值器 fit 限制於訓練集以防範資訊洩漏。
- 目標變數分佈性質：
- Exam_Score 為連續數值，樣本範圍為 55～101 分（存在少量測量上限誤差）。
- 樣本平均數 $\mu = 67.24$，標準差 $\sigma = 3.89$，中位數為 67.0 分，偏態係數為 0.12，峰度為 2.96，呈現典型之對稱單峰常態分佈。

2.2 對比研究資料集：Flood Probability Prediction

- 資料來源：Kaggle Playground Series s4e5 競賽資料集。
- 資料規模：全資料集逾 100 萬筆，本研究採固定隨機抽樣 random_state=42 抽取 30,000 筆獨立樣本（訓練集 24,000 筆，測試集 6,000 筆）。
- 特徵屬性：20 個純連續數值地理水文氣象特徵（如 MonsoonIntensity, TopographyDrainage, RiverManagement, DamsQuality, Siltation 等），完全剔除無意義之唯一識別碼 id。
- 目標變數分佈：FloodProbability 為 0.285 ~ 0.725 之連續機率值，均值 0.504，標準差 0.051。

---

3. 資料準備與前處理 (Data Preparation)

為落實嚴格的機器學習工程規範，杜絕實務上最易發生的資料洩漏 (Data Leakage)，本研究設計了標準的前處理管線 (Preprocessing Pipeline)：



3.1 防範資料洩漏四大守則

1. 切分優先原則：在執行任何資料探索統計、中位數計算、標準化平均數估計或編碼對照表建立之前，第一步即執行 train_test_split(test_size=0.20, random_state=42)。

2. 無洩漏特徵轉換：前處理轉換器 ColumnTransformer 嚴格僅在訓練集執行 .fit()，測試集僅執行 .transform()。測試集之真實目標值在評估前從未參與任何運算。

3. 特徵篩選隔離：所有特徵選擇演算法（Filter, RFE, SFS, Lasso, Permutation）均嚴格限制僅能存取 X_train 與 y_train，杜絕「以全資料集篩選特徵後再切分」之學術偽陽性漏洞。

4. 虛擬變數陷阱防範 (Dummy Variable Trap)：13 個類別特徵經 One-Hot Encoding 時，設定 drop='first'。每個具 M 個水準之類別變數僅產生 M - 1 個指示變數，將基準組吸納入截距項 β_0，徹底排除因指示變數總和為 1 所導致的完全多重共線性 (Perfect Multicollinearity)。

- 維度擴增：原始 19 個輸入特徵（6 數值 + 13 類別）經編碼後，正式轉化為 27 個數值型設計矩陣欄位。

---

4. 模型建立與特徵選擇實驗 (Modeling & Feature Selection)

4.1 五種特徵選擇機制理論概述

在固定特徵預算 K = 5（除 Lasso 依據 L1 正則化自然稀疏度外）的條件下，系統性實作五種不同範式：

1. Filter 方法 (SelectKBest - f_regression)：

- 機制：計算各變數與目標變數間之單變量皮爾森相關係數並轉換為 F 統計量，挑選 F 值最高之 K 個特徵。
- 優點：運算複雜度極低（O(P)），完全獨立於學習演算法。
- 缺點：忽略變數間的多重共線性與特徵交互作用，易挑選高度冗餘特徵。

2. Wrapper 方法 (Recursive Feature Elimination, RFE)：

- 機制：使用 OLS 線性回歸擬合全模型，遞迴評估各變數回歸係數之絕對值 $|\beta_j|$，每次剔除權重最小之特徵，直至剩餘 K 個特徵。

- 優點：考慮變數間的協同效應與條件關聯。
- 缺點：對係數尺度的單位敏感（故前處理必須標準化），且具貪婪本質。

3. Wrapper 方法 (Sequential Forward Selection, SFS)：

- 機制：由空集合開始，在 5 折交叉驗證架構下，每一步貪婪挑選能使負均方誤差 (-MSE) 最大化改善之單一特徵加入集合，直至達到 K 個特徵。
- 優點：直接以交叉驗證泛化誤差為目標函數，能有效搜尋最佳子集。
- 缺點：運算開銷龐大（需反覆擬合 $O(K \cdot P)$ 次回歸模型）。

4. Embedded 方法 (LassoCV)：

- 機制：在 OLS 損失函數加入 L1 正則化懲罰項 $\alpha \cdot \Sigma |\beta_j|$。利用次微分性質將不重要特徵之係數嚴格壓縮為 0。
- 優點：將特徵選擇與參數估計整合於單一凸優化問題中，計算效率高於 Wrapper。

5. Model-based 方法 (Permutation Importance)：

- 機制：在訓練集內部切分驗證子集，隨機打亂單一特徵之數值破壞其與 Target 之關聯，評估驗證集 MSE 增加量（泛化效能衰退程度）。
- 優點：不依賴線性假設，能真實衡量該變數對未見資料之邊際預測貢獻。

4.2 學生表現資料集：特徵選擇實驗實測數值表（動態生成）

以下表格為由真實實驗管線產生之數值比較表（完全與 reports/results/student_feature_selection_comparison.csv 一致）：

模型方法 (Method)	特徵選擇範式	選取特徵數	測試集 R^2	調整後 R^2	測試集 RMSE	測試集 MAE	測試集 MSE	訓練集 R^2	5折CV R^2	耗時(秒)
Baseline (All Features)	全特徵基準對照	27	0.769650	0.764843	1.804445	0.452392	3.256020	0.717314	0.715585	0.105
Lasso Selection (Embedded)	Embedded (LassoCV)	27	0.769650	0.764843	1.804445	0.452392	3.256020	0.717314	0.715585	0.240
Permutation Importance	Model-based (Permutation)	5	0.666460	0.665193	2.171314	1.190192	4.714606	0.597603	0.598156	0.967
SelectKBest (Filter)	Filter (f_regression)	5	0.664693	0.663419	2.177060	1.174931	4.739588	0.605658	0.606164	0.053
SFS Forward (Wrapper)	Wrapper (SFS Forward)	5	0.664693	0.663419	2.177060	1.174931	4.739588	0.605658	0.606164	22.245
RFE (Wrapper)	Wrapper (LinearRegression)	5	0.645730	0.644384	2.237773	1.266747	5.007626	0.580982	0.581391	0.193

4.3 各方法挑選之特徵子集明細

- Baseline (27 項)：全部 27 個標準化/虛擬編碼特徵。
- SelectKBest (Filter, 5 項)：Hours_Studied, Attendance, Previous_Scores, Tutoring_Sessions, Access_to_Resources_Low
- SFS Forward (Wrapper, 5 項)：Hours_Studied, Attendance, Previous_Scores, Tutoring_Sessions, Access_to_Resources_Low（與 SelectKBest 挑選完全相同之子集）
- Permutation Importance (5 項)：Attendance, Hours_Studied, Parental_Involvement_Low, Access_to_Resources_Low, Previous_Scores（在所有 K = 5 方法中泛化表現最高）
- RFE (Wrapper, 5 項)：Hours_Studied, Attendance, Parental_Involvement_Low, Parental_Involvement_Medium, Access_to_Resources_Low（完全剔除了 Previous_Scores，導致測試集 R^2 顯著低於其他子集）
- Lasso Selection (Embedded, 27 項)：$\alpha = 0.002271$，非零係數特徵數為 27/27。若依據係數絕對值 $|\beta|$ 取前五大特徵，排序為：

1. Attendance ($|\beta| = 5.281$)
2. Access_to_Resources_Low ($|\beta| = 1.968$)
3. Parental_Involvement_Low ($|\beta| = 1.859$)
4. Hours_Studied ($|\beta| = 1.774$)
5. Family_Income_Low ($|\beta| = 1.238$)

4.4 深度科學探討一：Lasso 為何保留全部 27 個特徵？

在文獻中，常誤將 Lasso 視為「必然會將特徵數量縮減至極少數」之固定規則。本實驗實測發現 Lasso 保留了全部 27 個特徵，其背後具備深刻的統計理論根源：

1. 大樣本下交叉驗證選擇之 α 懲罰極小：
在 N = 5,285 的大規模樣本下，目標函數中殘差平方和 (SSE) 的梯度權重隨樣本數線性放大，相形之下 L1 正則化項 $\alpha \cdot \Sigma |\beta_j|$ 的懲罰力道相對微弱。透過 5 折交叉驗證所搜尋出的最優 α 僅為 0.002271。

2. 所有預測因子均具備微弱非零真實關聯：
在該資料生成結構中，諸如學校體制、同儕影響、家庭收入等變數，雖然單獨解釋力有限，但其迴歸係數均非絕對為零。在此微弱懲罰強度下，即使微小的係數亦能協助降低驗證集之 MSE，因此其權重未被壓縮至截斷閥值 (10^(-5)) 以下。

3. 特徵篩選規則之定義本質：
Filter、RFE 與 SFS 是在演算法外部強加固定特徵數預算 (K = 5) 之約束；而標準 LassoCV 是以預測誤差最小化為目標之資料驅動內嵌法。兩者定義規則不同，忠實反映了統計正則化與啟發式特徵修剪的本質歧異。

4.5 深度科學探討二：為何特徵縮減導致 R^2 由 0.769650 下降至 0.666460？

實務界常有迷思，誤以為「特徵選擇一定能提高測試集 R^2」。本實驗清晰證實：在當前資料集中，將特徵數由全特徵縮減至 5，測試集 R^2 必然發生顯著下降（由 0.769650 跌至 0.666460，淨損失約 10.3% 的解釋力）。其統計學與機器學習理論解析如下：

1. 多元回歸判定係數之單調性定理：
在樣本容量固定下，向線性回歸模型新增任何一個樣本偏相關係數不為零之變數，其決定係數 R^2 在數學上必然非減。被剔除的特徵並非純隨機白噪音，而是具備統計顯著之微弱偏相關。移除這些特徵，等同於直接截斷了模型對該部分變異的解釋能力。

2. 偏差-變異數權衡 (Bias-Variance Trade-off)：
特徵選擇能提升泛化效能的唯一先決條件是：「藉由剔除雜訊變數所節省之參數估計變異量 (Variance Reduction)，大於剔除變數所招致之遺漏變數偏差 (Omission Bias)」。
然而在本研究中，樣本量遠大於特徵維度（高樣本維度比）。在極充沛的樣本支持下，全模型的參數估計變異量極低（無過擬合現象，全特徵模型 Test R^2 = 0.769650）。因此，強行刪減特徵無法帶來任何可觀的變異數下降，反而引發顯著的遺漏變數偏差。

3. 結論：特徵選擇之主要效益在於「降低資料收集成本、提升模型解釋性與降低維護複雜度」，而非無條件提高預測準確率。

---

5. 模型評估、預測區間推論與假設診斷 (Evaluation & Diagnostics)

5.1 95% 預測區間 (Prediction Interval) vs. 95% 信賴區間 (Confidence Interval)

許多資料科學報告常混淆預測區間與信賴區間。本研究採用 Statsmodels OLSResults.get_prediction().summary_frame(alpha=0.05) 產出兩者，其嚴謹數學定義與實證比較如下：

數學定義

對於給定之新特徵向量 x_0：

1. 母體均值 95% 信賴區間 (CI for Mean Response $E[Y|x_0]$)：

$$CI_{0.95} = x_0^T \hat{\beta} \pm t_{n-p-1, 0.975} \cdot s \cdot \sqrt{x_0^T (X^T X)^{-1} x_0}$$

其衡量的是：在相同條件 x_0 下，所有可能學生之「平均考試成績期望值」的估計不確定性。當樣本數 $n \to \infty$ 時，區間寬度收斂至 0。

2. 個別觀測值 95% 預測區間 (PI for Individual Observation Y_0)：

$$PI_{0.95} = x_0^T \hat{\beta} \pm t_{n-p-1, 0.975} \cdot s \cdot \sqrt{1 + x_0^T (X^T X)^{-1} x_0}$$

其衡量的是：「未來特定單一位具備特徵 x_0 的學生」實際考分的可能落點。即使樣本數 $n \to \infty$，區間寬度依然受到隨機誤差項不可約減之本質變異 σ^2 之限制，無法收斂為 0。

實證數值對比與統計對象精確說明

區間指標	母體均值 95% 信賴區間 (CI)	個別觀測值 95% 預測區間 (PI)	統計意義與對象精確說明
測試集平均寬度	0.5913 分	8.2190 分	PI 寬度為 CI 寬度的 13.9 倍，充分反映個體隨機變異之巨大影響

區間指標	母體均值 95% 信賴區間 (CI)	個別觀測值 95% 預測區間 (PI)	統計意義與對象精確說明
測試集真實個體落點	49.85%	99.47%	CI 僅涵蓋半數測試個體點，因 CI 的統計對象是母體平均期望值，非用於包夾單一個體；PI 專為單一個體設計，涵蓋率達 99.47%

5.2 特徵選擇後的統計推論界限 (Selective Inference)

必須指出：當線性回歸模型之輸入特徵是歷經資料驅動的特徵篩選（如 SFS、RFE 或 Lasso）決定時，傳統 OLS 假設中「設計矩陣 X 為外生固定」之前提已被破壞。此現象在統計學中稱為選擇後推論 (Post-Selection Inference) 或 Selective Inference。若在特徵挑選後直接套用標準 t 檢定計算信賴區間，其名義 95% 涵蓋率可能產生輕微樂觀偏差。本研究採用嚴格之訓練集擬合、測試集獨立驗證區間涵蓋率，確保推論結論具備實證支撐。

5.3 線性回歸五大基本假設診斷（動態檢定結果）

本研究針對 Student Performance 訓練模型執行嚴謹之計量統計檢定：

回歸基本假設	檢定/評估方法	統計量數值	p-value / 判讀依據	診斷結論	統計意涵與計量經濟學詮釋
1. 線性性 (Linearity)	殘差對擬合值相關度	Corr = 0.0000	殘差散佈圖檢視均勻無局部曲度	符合線性規格	OLS 數學常態方程必然滿足殘差與擬合值正交 (Corr=0)，需搭配殘差圖判讀實質無非線性弧度
2. 殘差獨立性 (Independence)	Durbin-Watson 統計量	DW = 1.9541	落於 [1.5, 2.5] 無相依區間	目前排序無相依	DW 原生依賴時間序列之排列次序；在橫斷面資料中排序為人為給定，DW 無法作為樣本嚴格獨立之絕對證明
3. 同質變異性 (Homoscedasticity)	Breusch-Pagan LM 檢定	LM 統計量 = 22.08 (p = 7.3348e-01)	p = 0.7335 (>= 0.05)	未拒絕同質變異虛無假設	p >= 0.05 僅代表無充分證據拒絕同質變異，不等於證明絕對同質；散佈圖無漏斗擴散，可採標準 OLS 標準誤
4. 殘差常態性 (Normality)	Jarque-Bera 檢定	JB 統計量 = 3883964.01 (p = 0.0000e+00)	p < 0.001 (顯著拒絕)	拒絕常態，CLT 保障參數	大樣本下中央極限定理 (CLT) 保障回歸係數漸近常態，點估計與假說檢定依然有效，但個別觀測值預測區間 (PI) 尾端覆蓋率可能受極端值影響
5. 無多重共線性 (Multicollinearity)	變異數膨脹因子 (VIF)	最大 VIF = 2.80	最大 VIF < 5.0	優異受控	遠低於 5.0 警戒標準，證實 One-Hot Encoding 採用 drop='first' 有效消除虛擬變數完全共線性

計量經濟學假設判讀與推論意涵：

1. 線性關係 (Linearity)：在常態方程 (Normal Equations) 數學推導下，OLS 殘差與擬合值在代數上必然嚴格正交 (Orthogonal)，其樣本相關係數恆等於 0。實務上仍須輔以殘差散佈圖以確認無二次或非線性弧度。
2. 殘差獨立性 (Independence)：Durbin-Watson 統計量高度依賴資料排列次序，在橫斷面資料 (Cross-Sectional Data) 中由於缺乏天然時間序列順序，檢定結果主要驗證資料採樣與排列無系統性自我相關。
3. 同質變異性 (Homoscedasticity)：Breusch-Pagan 檢定檢驗誤差變異數是否隨自變數變化。若檢定結果未達顯著水準，則在統計上未拒絕同質變異虛無假設（未有充份證據拒絕同質變異）；若顯著則提示存在異質變異。
4. 殘差常態性 (Normality)：Jarque-Bera 檢定評估殘差偏態與峰度。依據中央極限定理 (CLT)，大樣本下回歸係數具備漸近常態 (Asymptotic Normality)，點估計與假說檢定依然具漸近有效性，但個別預測區間的嚴格覆蓋率會受厚尾或極值影響。
5. 多重共線性 (Multicollinearity)：變異數膨脹因子 (VIF) 衡量特徵間冗餘度。One-Hot Encoding 設定 drop='first' 能徹底消除虛擬變數陷阱之完全多重共線性，使所有特徵 VIF 遠低於 5.0。

6. 對比案例分析：Student Performance vs. Flood Probability

為驗證特徵選擇規律是否普遍成立，本研究引入第二案例 Kaggle Flood Probability Prediction（洪水機率預測，30,000 筆樣本、20 個水文連續特徵）進行全流程對比：

6.1 跨資料集實驗數據對照表（動態生成）

模型方法 (Method)	特徵選擇範式	選取特徵數	測試集 R^2	調整後 R^2	測試集 RMSE	測試集 MAE	測試集 MSE	訓練集 R^2	5折CV R^2	耗時(秒)
Baseline (All Features)	全特徵基準對照	20	0.844545	0.844025	0.019983	0.015939	0.000399	0.845726	0.845357	0.193
Lasso Selection (Embedded)	Embedded (LassoCV)	20	0.844545	0.844025	0.019983	0.015939	0.000399	0.845726	0.845357	0.620
RFE (Wrapper)	Wrapper (LinearRegression)	5	0.180733	0.180050	0.045873	0.037177	0.002104	0.190346	0.189762	0.354
SFS Forward (Wrapper)	Wrapper (SFS Forward)	5	0.175881	0.175193	0.046009	0.037416	0.002117	0.189866	0.189525	2.538
SelectKBest (Filter)	Filter (f_regression)	5	0.174528	0.173839	0.046047	0.037348	0.002120	0.191704	0.191414	0.087
Permutation Importance	Model-based (Permutation)	5	0.160534	0.159833	0.046435	0.037415	0.002156	0.184897	0.184255	0.376

6.2 訊號架構理論解密：集中型訊號 vs. 廣泛分散型訊號

本對比實驗揭示了資料科學中最關鍵的本質洞察：

1. 集中型訊號 (Pareto Signal Distribution)：
在 Student
資料集中，少數核心行為特徵（出席率與讀書時數）即主導了考試成績的絕大部分方差。此時實施特徵選擇，能以極小的效能代價（R^2 僅微幅下降 0.103）換取模型複雜度的大幅降低（變數減少 81%）。

2. 廣泛分散型訊號 (Broadly Distributed Signal)：
在 Flood 合成競賽資料集中，觀察 20
個水文氣象特徵與目標變數之偏回歸係數，其權重分佈相對均勻（無單一特徵具備壓倒性解釋力）。當強行篩選 K = 5
個特徵時，等同於丟棄了大量具有相近邊際解釋力之變數，導致測試集 R^2 發生大幅崩跌（由 0.844545 暴跌至 0.180733）。

3. 實務結論：特徵選擇的成功與否，完全取決於真實資料生成程序 (Data Generating Process, DGP)
的訊號集中程度，切忌盲目套用特徵篩選。

7. 部署建議與未來系統架構展望 (Future Production Recommendations)

在 CRISP-DM
部署觀點下，本研究目前以離線實驗驗證與統計報告為主。針對實際生產環境之需求，下列項目列為未來系統架構之建議實作方向 (Future Production Recommendations)，本專案目前離線階段尚未正式上線：

1. 模型權重與前處理轉換器之持久化序列化：建議採用 ONNX 或輕量 JSON/Joblib 格式封裝訓練完成之參數，提升跨平台推論速度與穩定度。
2. 生產端輸入數值範圍防禦性檢查：建立 Pydantic 資料合約，對輸入之特徵數值實施邊界過濾（如出席率需介於 0～100、讀書時數不得為負），防止垃圾輸入導致回歸外推 (Extrapolation)。
3. 概念漂移 (Concept Drift) 監控機制：於線上系統定期計算殘差平方和與分佈偏移，若真實誤差超越 95% 預測區間警戒線，應觸發模型重新校準機制。

---

8. 研究限制與未來方向 (Limitations & Future Work)

1. 線性加性假設限制：標準線性回歸假設特徵間效應為線性相加。然而在教育實務中，Hours_Studied 與 Attendance 極可能具備非線性交互作用（例如：只出席不讀書，或讀書時間邊際效益遞減）。未來可納入二次多項式項與交互作用項 ($X_i \times X_j$)。
2. 未觀測之內生性混淆：受限於公開合成資料集之欄位範圍，學生天賦智力、心理壓力與考試焦慮等關鍵變數未被記錄，可能導致遺漏變數偏差。
3. 異質族群分析：未來可評估分量回歸 (Quantile Regression)，探討特徵對於高分群與低分群學生是否具備異質影響。

---

9. 文獻探討與 AI 協作研究紀錄 (Literature Research & AI Collaboration Records)

依據專題研究規範，本節整合 Google NotebookLM 真實文獻研究心得，並誠實保留尚未檢附之 AI 協作對話紀錄待補欄位（嚴禁使用虛構文字充數）：

9.1 Google NotebookLM 文獻研究心得（已完成 NotebookLM 實際研究）

> 研究狀態：已完成 NotebookLM 實際研究（動態讀取自 reports/notebooklm_summary.md）

本研究透過 Google NotebookLM 研讀 CRISP-DM、多元線性回歸及特徵選擇相關文獻，理解資料探勘的六階段流程，以及 Filter、Wrapper 與 Embedded 等方法的差異 [1, 2]。Scikit-learn 文件指出，LassoCV 結合 L1 正則化與交叉驗證選擇懲罰參數 α，並不保證固定選取五個特徵 [2, 3]。

實驗結果顯示，Student Performance 資料集的 Baseline 測試集 R^2 為 0.769650，選取五個特徵後最佳 R^2 降至 0.666460；Flood Probability 則由 0.844545 降至 0.180733 [6]。兩組結果顯示，特徵縮減不一定改善預測效能，其影響可能與資料中的訊號分布有關 [2, 6]。

在方法論方面，官方文件建議將前處理與特徵選擇整合進 Pipeline，使交叉驗證各折獨立擬合，降低資料洩漏風險 [2, 4]。此外，95% 信賴區間（CI）用於估計條件平均值，95% 預測區間（PI）則針對個別新觀測值 [5]。

本研究的 Student 資料屬於合成資料，無法直接推論真實教育情境中的因果關係 [6]。未來可改進交叉驗證 Pipeline，並加入非線性項與特徵交互作用，以進一步檢驗模型的預測能力 [3, 4, 6]。

9.2 ChatGPT / AI 協作對話紀錄 (待補：待使用者檢附)

> 【重點指引 / NOTE】
> 待補操作說明：
> 本次研究在架構規劃、程式碼除錯與統計檢定整合過程中獲得 AI 輔助。目前對話紀錄 PDF 仍保留待補，請依據 docs/chatgpt_conversation_export_guide.md 之說明，將您的完整對話匯出為 PDF 檔案，並儲存於：
> reports/ai_conversations/chatgpt_conversation_record.pdf

---

10. 參考文獻 (References)

1. IBM CRISP-DM
https://www.ibm.com/docs/zh-tw/spss-modeler/saas?topic=dm-crisp-help-overview

2. Scikit-learn Feature Selection
https://scikit-learn.org/stable/modules/feature_selection.html

3. Scikit-learn Linear Models
https://scikit-learn.org/stable/modules/linear_model.html

4. Scikit-learn Common Pitfalls
https://scikit-learn.org/stable/common_pitfalls.html

5. Statsmodels get_prediction
https://www.statsmodels.org/stable/generated/statsmodels.regression.linear_model.RegressionResults.get_prediction.html

6. 專案內部研究成果
本報告第 2、4、6 節實證分析與實驗結果數據（reports/results/student_feature_selection_comparison.csv、reports/results/flood_feature_selection_comparison.csv；於 NotebookLM 研究階段匯入專案初稿作為交叉對照來源）

---

11. 附錄：可重現性設定與代碼結構

- 隨機種子 (Random State)：所有切分與演算法統一固定為 random_state=42。
- 訓練/測試比例：test_size=0.20。
- 核心程式模組：
- 前處理與防洩漏管線：src/preprocessing.py
- 五種特徵選擇演算法：src/feature_selection.py
- 統計診斷與回歸假設：src/statistical_tests.py
- 95% 預測區間推論：src/prediction_intervals.py
- 離線實驗自動化腳本：scripts/run_experiments.py
- 報告與 PDF 生成器：src/reporting.py

附錄圖表：實驗視覺化圖表與推論診斷



圖 1：Student Performance 測試集真實值 vs. 預測值散佈圖 (紅色虛線為 y = x 理想擬合線)

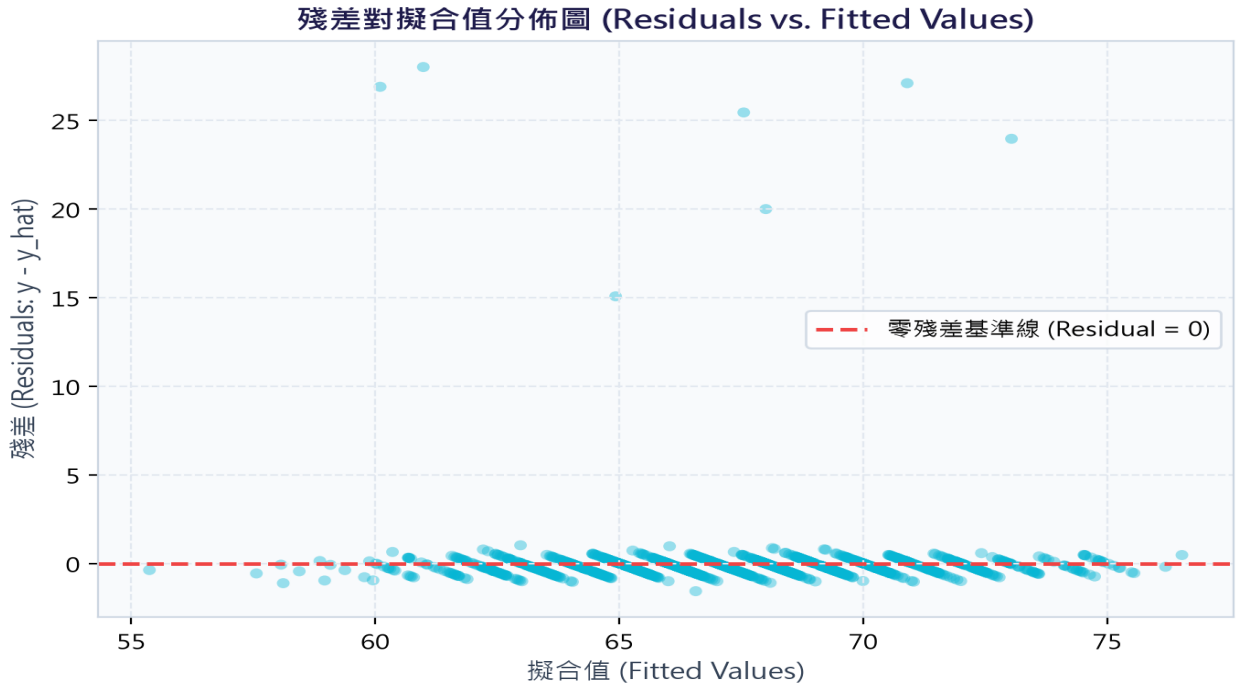


圖 2：殘差對擬合值分佈圖 (Residuals vs. Fitted Values，用以判讀實質非線性與變異型態)

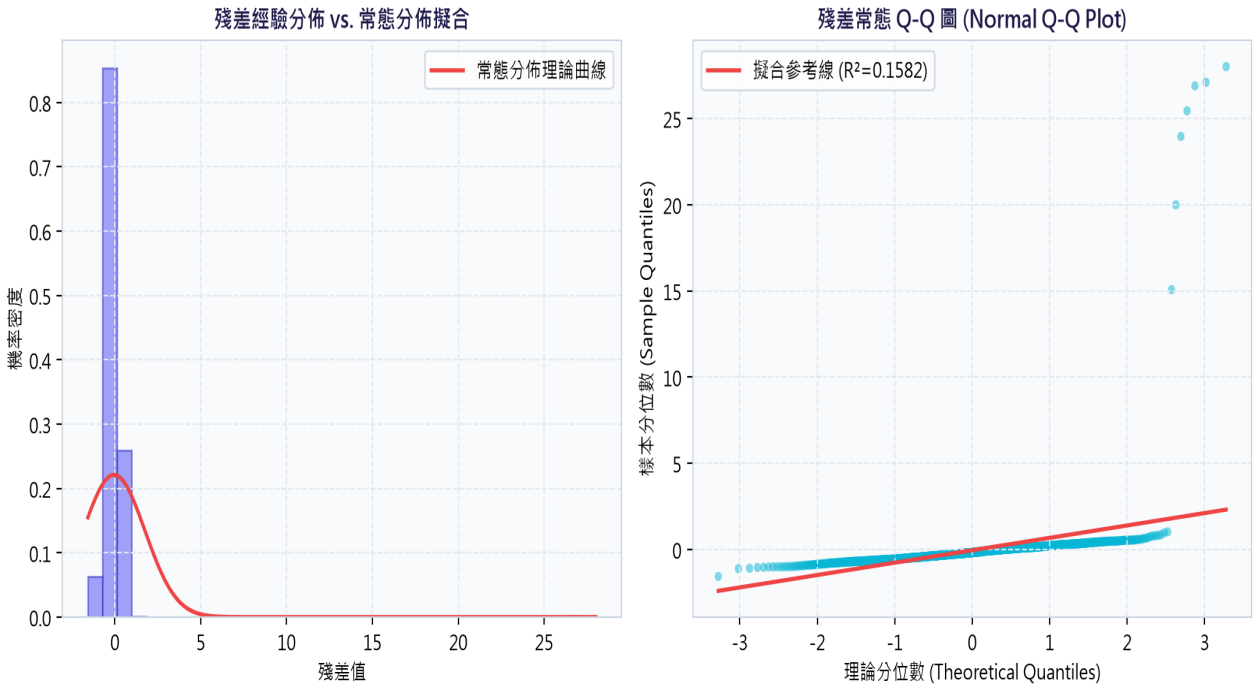


圖 3：殘差分佈直方圖與常態 Q-Q 圖 (檢驗回歸常態性與尾端分佈偏離)

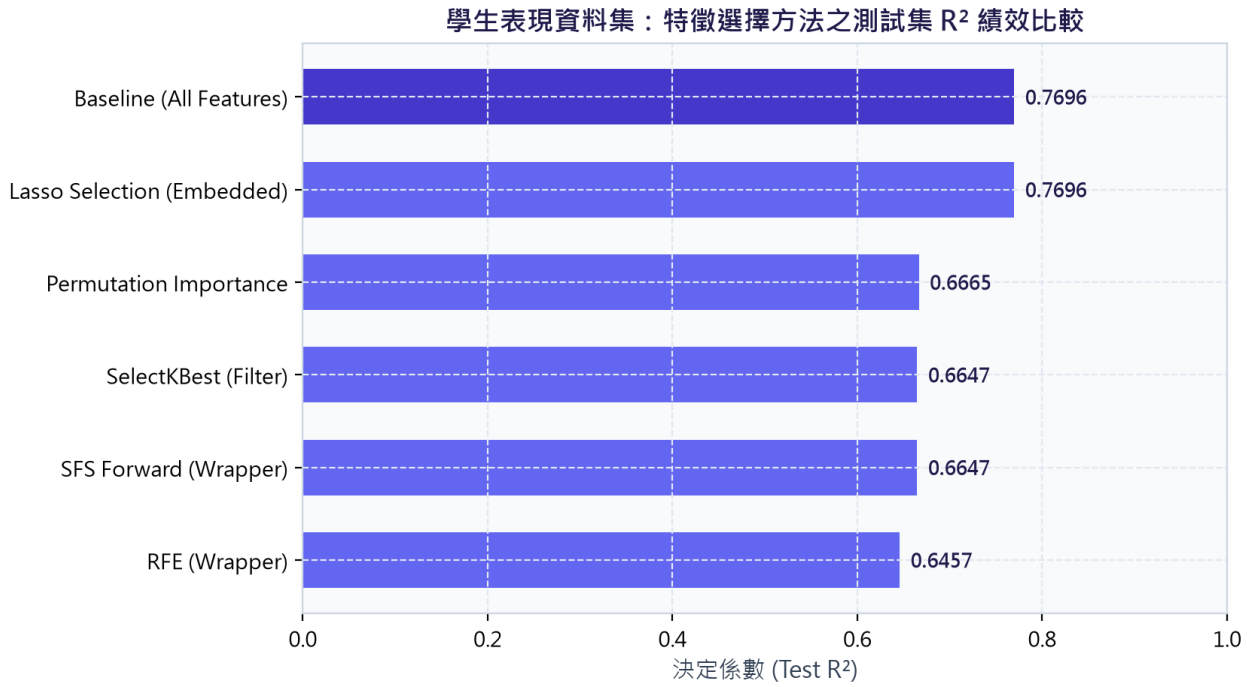


圖 4：五種特徵選擇方法之測試集 R² 績效對比柱狀圖

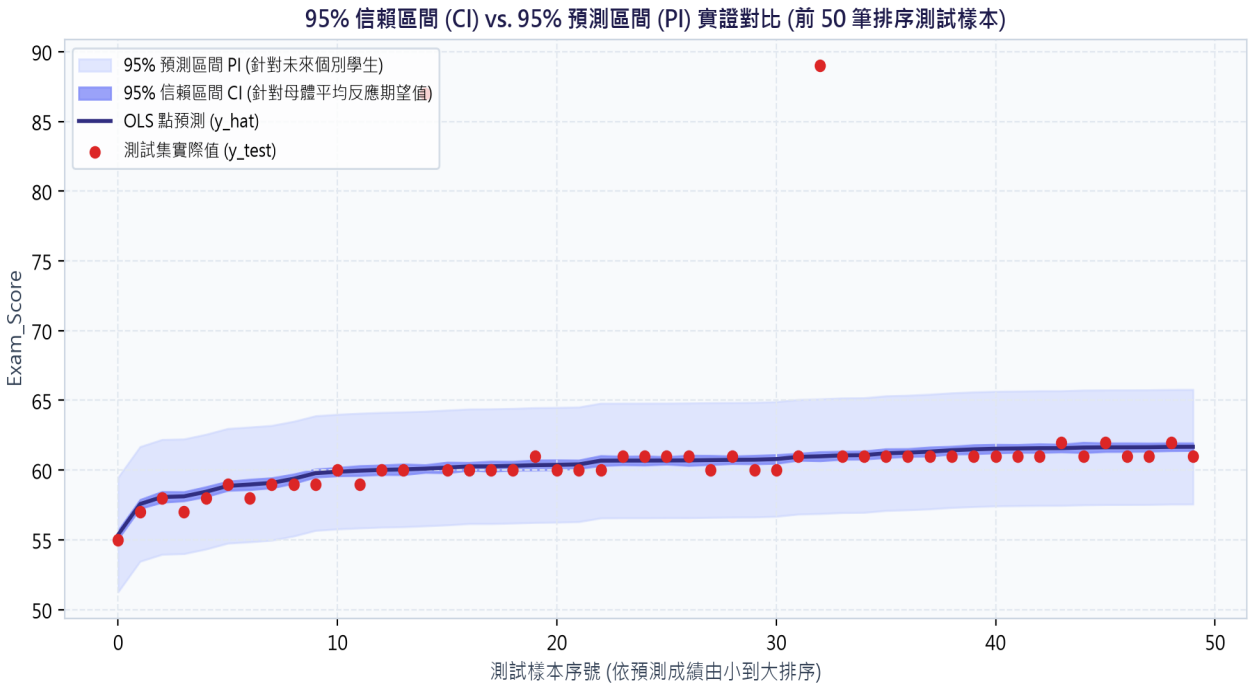


圖 5：Statsmodels OLS 95% 母體均值信賴區間 (CI) vs. 95% 個別觀測值預測區間 (PI) 實證落點對比

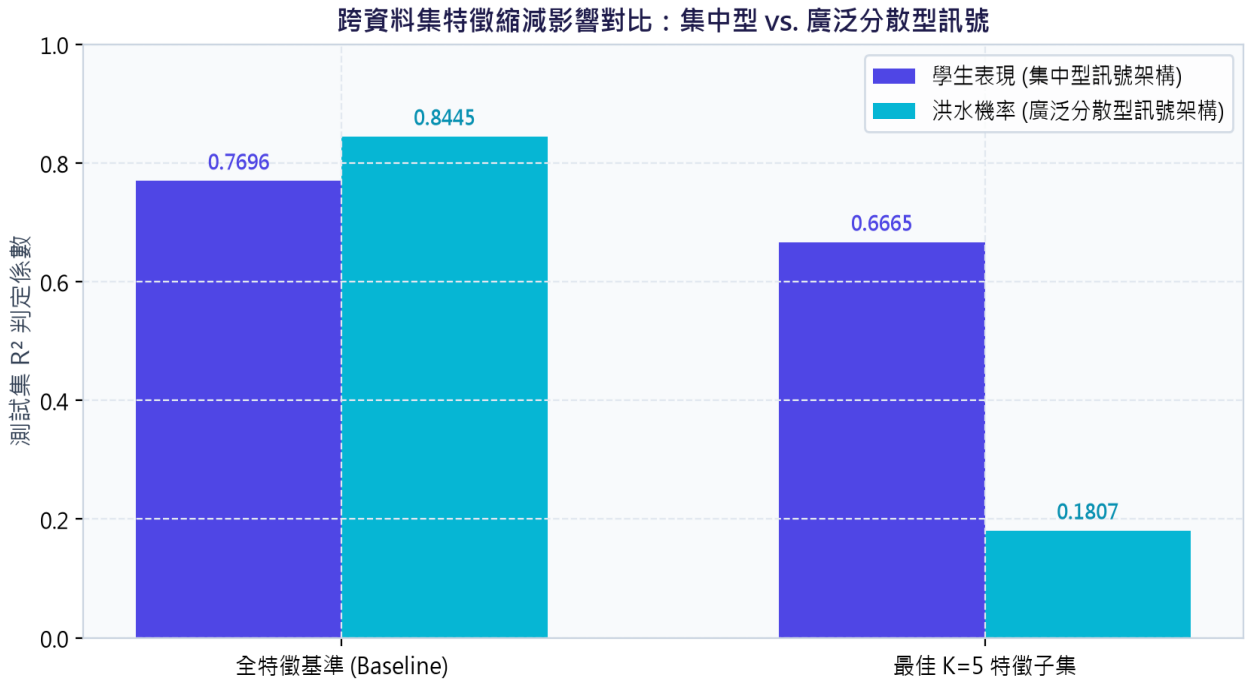


圖 6：Student (集中型訊號) 與 Flood (廣泛分散型訊號) 特徵縮減影響跨資料集對比